Checklist de EDA

Guia de boas práticas para análise exploratória de dados orientada a decisão de negócio

1. Alinhamento de Negócio e Escopo

- ☐ **Tradução de dores em hipóteses testáveis:** liste as perguntas que estão travando decisões da diretoria e isole as hipóteses prévias das áreas de negócio para validá-las ou refutá-las com evidência estatística.
- ☐ **Definição da granularidade:** identifique exatamente o que representa cada linha da tabela (um pedido, um item, um jogo único), o volume total de registros e a janela de tempo coberta pelo dataset.
- ☐ **Trava de escopo:** confirme as restrições da demanda — por exemplo, se o cliente precisa de um diagnóstico visual para tomada de decisão imediata em vez de modelos preditivos.

2. Auditoria de Qualidade e Saneamento

- ☐ **Integridade de importação e tipagem:** verifique codificação de caracteres (UTF-8), delimitadores de texto, separadores decimais e tipagem correta de datas, textos e números.
- ☐ **Mapeamento de dados ausentes (*missings*):** quantifique o percentual de valores vazios e investigue se a ausência ocorre de forma aleatória ou se concentra em recortes específicos (viés **MNAR** — *Missing Not at Random*, como falta de avaliações concentrada em produtos caros ou categorias específicas). Documente se optou por trabalhar sem imputação para não fabricar dados artificiais.
- ☐ **Anomalias, duplicidades e zeros estruturais:** procure registros duplicados pela chave primária e documente comportamentos atípicos na base. Separe zeros que representam erro de coleta daqueles que representam uma característica real do produto (ex.: itens gratuitos com `price = 0` ou produtos comprados e nunca utilizados com `playtime = 0`).
- ☐ **Tratamento de campos multivalorados:** quando uma coluna concatena várias categorias na mesma célula (ex.: `Action;Indie;RPG`), defina a regra de negócio antes de agregar valores para não duplicar contagens de volume ou somas de receita.

3. Engenharia de Variáveis para Diagnóstico

- ☐ **Criação de métricas de negócio e pesos financeiros:** números brutos isolados escondem a estrutura do problema. Construa indicadores relativos (taxas de aprovação/rejeição) e estimativas de receita/volume para dimensionar o peso financeiro de cada segmento analisado.
- ☐ **Agrupamento em faixas (*binning*):** transforme variáveis contínuas de alta dispersão em faixas lógicas de negócio (como faixas de atraso, faixas de preço ou faixas de retenção) para verificar se o impacto na satisfação é monotônico à medida que se avança de faixa.

4. Análise Univariada e Rigor Amostral

- ☐ **Medidas de tendência central e dispersão:** compare média e mediana; em distribuições fortemente assimétricas (muito comuns em preços, receitas e tempo de uso), a média sozinha distorce a leitura.

- ☐ **Corte de relevância amostral:** nunca monte rankings de melhores ou piores segmentos com toda a base indiscriminadamente; defina e aplique um volume mínimo de observações (ex.: mínimo de 100 avaliações) para impedir que categorias minúsculas dominem os extremos por sorte ou azar estatístico.
- ☐ **Intervalos de Confiança (95%):** calcule a margem de erro para as médias de cada grupo. Segmentos cujos intervalos de confiança se sobrepõem à média geral ou entre si são estatisticamente indistinguíveis e não permitem conclusões definitivas.

5. Análise Multivariada, Sazonalidade e Armadilhas Analíticas

- ☐ **Cruzamento de desempenho com tamanho de mercado:** um segmento com avaliação péssima, mas que representa 0,01% do faturamento, não é prioridade executiva. Cruze sempre os piores indicadores de satisfação com a representatividade em volume de vendas e percentual da receita total.
- ☐ **Correlação e poder explicativo:** calcule a correlação linear de Pearson (r) e a variância explicada (R^2) *entre as variáveis operacionais e a satisfação. Calibre a leitura: em dados comportamentais ruidosos, uma correlação moderada (*$|r| \approx 0{,}30$, explicando 9% da variância) já representa um sinal forte de negócio, enquanto $|r| \approx 0{,}10$ indica impacto prático irrelevante.
- ☐ **Série temporal (taxa relativa vs. volume absoluto):** ao avaliar sazonalidade e picos de demanda, plote o volume de transações junto com a métrica de qualidade. Não caia na armadilha dos percentuais estáveis: uma taxa de rejeição constante em um mês onde o volume dobra significa o dobro de clientes reais insatisfeitos pressionando a operação e a reputação da marca.

6. Síntese Executiva e Limitações Metodológicas

- ☐ **Distinção entre correlação e causalidade:** mapeie possíveis variáveis confundidoras que a base não controla e deixe registrado que associações observadas não provam causa e efeito sem testes controlados (como testes A/B).
- ☐ **Recomendações orientadas a custo vs. impacto:** feche a investigação propondo intervenções práticas focadas na variável de maior peso explicativo e nos segmentos de maior impacto financeiro, destacando ações de baixo custo operacional.