Modelo de Documentação Técnica de EDA

Estrutura de escrita em seis etapas para relatórios executivos de análise exploratória

> *Os trechos entre colchetes `[ ]` são campos a preencher em cada projeto.*

Etapa 1: Alinhamento de Negócio e Escopo

Objetivo do bloco: deixar claro em um parágrafo por que a análise existe, quais perguntas de negócio serão respondidas e qual é a granularidade exata da base.

Modelo de escrita

- **Contexto e Problema:** a área de `[nome da área, ex.: Operações / Portfólio]` reportou `[problema central, ex.: queda no NPS / travamento na alocação de orçamento]`, onde os indicadores consolidados escondem a estrutura real do problema.
- **Perguntas Norteadoras:** a partir do alinhamento com `[Nome e Cargo do Stakeholder]`, o diagnóstico foi estruturado em três frentes:
  1. `[Pergunta 1, ex.: a rejeição é uniforme ou concentrada em segmentos específicos e financeiramente relevantes?]`
  2. `[Pergunta 2, ex.: qual o peso relativo da variável X versus a variável Y na satisfação do cliente?]`
  3. `[Pergunta 3, ex.: existem padrões sazonais que degradem a avaliação ou aumentem o volume crítico em períodos de pico?]`
- **Escopo e Granularidade dos Dados:** o dataset compreende `[N]` registros únicos de `[granularidade, ex.: pedidos / jogos]`, cobrindo o período de `[Mês/Ano inicial]` a `[Mês/Ano final]`. O escopo restringe-se a diagnóstico descritivo e visual, excluindo modelos preditivos nesta fase.

Etapa 2: Auditoria de Qualidade e Saneamento (*Data Profiling*)

Objetivo do bloco: declarar anomalias, dados ausentes, vieses de coleta e regras de limpeza sem esconder sujeira debaixo do tapete.

Modelo de escrita

- **Integridade e Tipagem:** a base bruta foi importada via Power Query com codificação `[ex.: UTF-8]`, padronização de separadores decimais e verificação de duplicidades pela chave primária (`[nome_da_coluna_id]`).
- **Dados Ausentes e Viés Amostral (MNAR):** identificou-se que aproximadamente `[X]`% dos registros apresentam ausência ou valores zerados na variável `[nome da coluna]`. Essa ausência não é aleatória: concentra-se em `[descrever recorte, ex.: pedidos de alto valor / jogos gratuitos ou sem engajamento]`. Optamos por trabalhar com os dados válidos sem imputação artificial para não distorcer a distribuição original, reportando essa limitação nas conclusões.
- **Tratamento de Campos Multivalorados e Textuais:**
  - A coluna `[ex.: genres]` continha múltiplos atributos concatenados por `[delimitador]`. A regra de negócio adotada foi `[explicar se extraiu a categoria primária ou se desmembrou em tabela auxiliar]`, garantindo que a soma de volume e receita não sofresse dupla contagem.

- A coluna `[ex.: owners]`, originalmente em texto de faixa (`[ex.: 20000-50000]`), foi dividida em limite inferior e superior para derivação do ponto médio numérico.

Etapa 3: Engenharia de Variáveis para Diagnóstico

Objetivo do bloco: documentar as fórmulas exatas e a lógica de negócio por trás de colunas criadas e agrupamentos (*binning*).

Modelo de escrita

Variável Criada	Fórmula / Lógica Aplicada	Justificativa de Negócio
`[Ex.: Total_Avaliacoes]`	`[Col_Positivas] + [Col_Negativas]`	Dimensionar a relevância estatística de cada registro antes de calcular taxas relativas.
`[Ex.: Taxa_Aprovacao]`	`[Col_Positivas] / [Total_Avaliacoes]`	Indicador padronizado (0 a 100%) para comparar satisfação entre produtos de diferentes escalas.
`[Ex.: Receita_Estimada]`	`[Preco] * [Ponto_Medio_Volume]`	Estimar a representatividade financeira de cada segmento no faturamento global.
`[Ex.: Faixas_Engajamento]`	Segmentação em `[N]` faixas: `[Faixa 1]`, `[Faixa 2]`...	Avaliar se a relação entre `[variável]` e satisfação é monotônica ao longo das faixas.

Etapa 4: Análise Univariada e Rigor Amostral

Objetivo do bloco: justificar os cortes de amostra para provar que seu ranking não é fruto de sorte ou azar estatístico.

Modelo de escrita

- **Corte de Relevância Amostral:** para evitar que produtos ou categorias com baixo volume distorçam os extremos do ranking, restringimos a análise a registros com no mínimo `[N]` avaliações e segmentos com pelo menos `[M]` itens ativos.
- **Margem de Erro e Significância:** as médias de cada segmento foram avaliadas com Intervalos de Confiança de 95% (IC 95% = $\bar{x} \pm t \cdot s / \sqrt{n}$). Segmentos com volume abaixo de `[X]` observações apresentaram intervalos sobrepostos à média geral (`[valor da média geral]`), sendo classificados como estatisticamente indistinguíveis. Apenas as categorias nos extremos com separação clara de intervalo sustentam recomendações definitivas.

Etapa 5: Análise Multivariada, Sazonalidade e Armadilhas Analíticas

Objetivo do bloco: conectar os achados estatísticos ao impacto financeiro e operacional, separando taxas relativas de volume absoluto.

Modelo de escrita

- **Cruzamento Satisfação vs. Relevância Financeira:** os `[N]` segmentos com pior avaliação média apresentam uma amplitude de `[X]` pontos percentuais abaixo do topo do ranking e, em conjunto, respondem por aproximadamente `[Y]`% da receita estimada total — descartando a hipótese de serem nichos irrelevantes.
- **Teste de Hipóteses via Correlação:** a correlação linear de Pearson entre `[Variável A]` e a satisfação é de r = `[valor]` (*R*² = `[valor]`%), o que representa um sinal `[forte/moderado/fraco]`

considerando a natureza ruidosa de dados comportamentais. Em contrapartida, a variável `[Variável B]` apresentou correlação de apenas r = `[valor]`, refutando a hipótese inicial da área de `[nome da área]`.

- **Sazonalidade e Armadilha dos Números Relativos:** a série histórica aponta picos de volume nos meses de `[meses]`, enquanto a taxa média de satisfação mantém-se `[estável / em queda]`. Ressalta-se que uma taxa de rejeição estável de `[X]`% durante um pico onde o volume dobra resulta no dobro de clientes reais insatisfeitos, elevando o custo reputacional absoluto.

Etapa 6: Síntese Executiva, Recomendações e Limitações

Objetivo do bloco: traduzir a análise em plano de ação priorizado por custo/impacto e blindar o trabalho apontando o que os dados não provam.

Modelo de escrita

- **Recomendações Priorizadas:**
  1. `[Ação 1 focada nos segmentos de maior receita e pior nota]`: impacto potencial estimado em `[X pontos/%]` na aprovação média das categorias críticas.
  2. `[Ação 2 de baixo custo / alto impacto na variável de maior correlação]`: intervenção de custo operacional próximo de zero focada em `[descrever alavanca]`.
- **Limitações Metodológicas:**
  - **Correlação não implica causalidade:** variáveis confundidoras não controladas na base (como `[ex.: marketing do estúdio, escopo do jogo ou gênero]`) podem influenciar simultaneamente `[Variável X]` e a satisfação.
  - **Precisão das Estimativas:** valores monetários em `[moeda]` nominais do período e volume de vendas baseado em ponto médio de faixas públicas.
- **Próximos Passos Sugeridos:** condução de `[ex.: estudo controlado por faixa de orçamento / coleta de dados mais granulares de retenção]` para isolar o efeito causal antes de comprometer investimentos de longo prazo.